Manual de usuario de DataExtractionGP

Extractor de datos del Congreso del Estado de Puebla (LXII Legislatura) para el área de Bien Común de la UPAEP.

Programa	DataExtractionGP.exe (Windows 10 u 11)
Resultado	Siete bases de datos en Excel sobre la LXII Legislatura (2024-2027).

Este manual explica cómo usar el programa paso a paso. No necesitas saber programar ni instalar nada adicional: basta con abrir `DataExtractionGP.exe` desde su carpeta, elegir una opción del menú y esperar a que el programa genere los archivos de Excel.

1. ¿Qué hace el programa?

DataExtractionGP descarga información pública del sitio del Congreso del Estado de Puebla (congresopuebla.gob.mx), la procesa y entrega siete bases de datos en archivos de Excel. Una parte de la información está en páginas web y otra en documentos PDF (actas, gacetas mensuales y versiones estenográficas); el programa los descarga y los lee por ti.

Algunas bases usan inteligencia artificial (Gemini, de Google) para leer los PDF y necesitan una clave personal (sección 4). Las demás no usan inteligencia artificial.

Para cada base, el programa hace lo mismo de forma automática y en este orden:

1. **Descarga y procesa** los datos. Es la etapa más larga.
2. **Genera el Excel** con el formato de la plantilla original.
3. **Revisa el Excel** contra otra fuente y marca las diferencias con colores y comentarios. Esta etapa solo existe en las opciones 2 y 4.

Tú solo eliges el número de la base en el menú.

Opción	Base de datos	Excel que se genera	¿Necesita clave de IA?	Ejecútala antes
1	Perfiles	Perfiles.xlsx	No	—
2	Votaciones	Votaciones.xlsx	No	Opción 3 (para la revisión final)
3	Unidad y participación	Unidad y Participación.xlsx	Sí	—
4	Asistencias	Asistencias.xlsx	No	Opción 6 (Opcional, tambien puede descargar los archivos necesarios por su cuenta)
5	Comisiones y comités	Comisiones.xlsx	Sí (solo una hoja)	—
6	Sesiones	Sesiones.xlsx	No	—

Opción	Base de datos	Excel que se genera	¿Necesita clave de IA?	Ejecútala antes
7	Iniciativas y puntos de acuerdo	Iniciativas y PA.xlsx	Opcional (el programa pregunta)	Opciones 1 y 5

2. Antes de empezar

- Una computadora con Windows 10 u 11.
- Conexión estable a internet. Todas las bases descargan información del sitio del Congreso.
- Espacio libre en disco. Los PDF se guardan en tu computadora y una sola gaceta mensual puede superar las mil páginas.
- Excel o un programa compatible para abrir los resultados.
- La carpeta completa del programa (sección 3). El archivo `DataExtractionGP.exe` no funciona si lo separas de sus carpetas.
- Una clave de API de Gemini, solo si vas a ejecutar las opciones 3 y 5, o la 7 respondiendo que sí quieres usar IA. La sección 4 explica cómo obtenerla.

3. Preparar la carpeta del programa

El programa se entrega como una carpeta llamada `DataExtractionGP` que contiene el ejecutable y las demás carpetas que necesita. Conserva esta estructura tal como viene:

```
DataExtractionGP/
  DataExtractionGP.exe   Programa: se abre con doble clic
  .env                   Clave de IA (la creas tú; ver sección 4)
  data/                  Datos descargados y avance (no borrar)
  outputs/               Aquí aparecen los Excel terminados
  scrappers/             Partes internas del programa:
  writers/               no las muevas, no las renombres
  verification/          y no las borres
  extractors/
  lib/
  prompts/
```

Dentro de `data` el programa guarda los PDF descargados (carpeta `pdfs`) y las fotos de los diputados (carpeta `photos`). Si junto al ejecutable ves una carpeta llamada `_internal`, también es parte del programa: no la muevas ni la borres.

1. Si recibiste la carpeta comprimida (ZIP), haz clic derecho sobre ella y elige «Extraer todo». No abras el programa desde dentro del ZIP.
2. Coloca la carpeta en una ruta corta, sin acentos ni espacios. Por ejemplo: `C:\DataExtractionGP`.

3. Ábrela y comprueba que ves `DataExtractionGP.exe` junto a las carpetas de la lista. A veces al extraer se crea una carpeta dentro de otra con el mismo nombre; en ese caso entra a la carpeta interior.

> **Resultados de ejecuciones anteriores**
> Las carpetas `data` y `outputs` pueden traer resultados de ejecuciones anteriores. Sirven como punto de partida: las opciones 3 y 5 reconocen lo ya procesado y solo trabajan con documentos nuevos o pendientes.
>
> Si prefieres empezar de cero, vacía esas dos carpetas antes de ejecutar (vacía su contenido; no borres las carpetas).

4. Configurar la clave de IA (opciones 3, 5 y 7 con IA)

Las opciones 3 (Unidad y participación) y 5 (Comisiones y comités) envían texto de documentos a la inteligencia artificial de Google y necesitan una clave personal; sin ella no pueden funcionar. La opción 7 pregunta si quieres usar IA: si respondes No, no necesita clave. Las opciones 1, 2, 4 y 6 no usan IA, así que si solo vas a ejecutar esas puedes saltarte esta sección. La clave se configura una sola vez.

1. Entra a Google AI Studio (https://aistudio.google.com/apikey) con una cuenta de Google y crea una clave con la opción «Get API key» o «Crear clave de API». Copia el texto de la clave.
2. Abre el Bloc de notas y escribe una sola línea, sin comillas y sin espacios alrededor del signo igual:

```
GEMINI_API_KEY=pega_aqui_tu_clave
```

3. Elige Archivo, Guardar como, y cambia «Tipo» a «Todos los archivos».
4. Escribe `.env` como nombre del archivo (con el punto al inicio y nada más) y guárdalo dentro de la carpeta `DataExtractionGP`, junto a `DataExtractionGP.exe`.
5. Comprueba que no quedó como `.env.txt`: en el Explorador de archivos activa Ver, Mostrar, Extensiones de nombre de archivo.

> **Atención**
> La clave equivale a una contraseña con posible costo asociado. No la compartas ni la pegues en correos. Si se filtra, bórrala en AI Studio y crea otra.

5. Usar el programa

1. Haz doble clic en `DataExtractionGP.exe`. Se abre una ventana con la tabla «Orquestador de Extracción de Datos»: las siete bases de datos y, debajo, las carpetas donde se guardarán los datos y los Excel.

2. Escribe el número de la base que quieres extraer y presiona Enter. Para salir, escribe 0.
3. Espera. El programa ejecuta las etapas en orden y avisa de cada una:

Mensaje en pantalla (N = número de la base)	Qué está haciendo
«Ejecutando scrappers/scriptN.py»	Descarga y procesa los datos. Es la etapa más larga y muestra su avance en pantalla.
«Ejecutando writers/scriptN.py»	Genera el Excel.
«Ejecutando verification/scriptN.py»	Revisa el Excel contra otra fuente. Solo en las opciones 2 y 4; en las demás, el programa indica que no hay revisión y sigue.

Los mensajes con marca verde indican éxito y los marcados en rojo indican un error. Si falla una etapa, el programa se detiene y no ejecuta las siguientes. Al terminar aparece «Proceso completo … finalizado con éxito» y el programa pide presionar Enter para volver al menú.

Opción 7: pregunta sobre la IA

Antes de empezar, la opción 7 pregunta «¿Usar IA para llenar 'Contenido' y 'Comentario'? (Si/No)». Escribe **No** para una extracción solo con reglas (más rápida y sin costo; esas dos columnas quedan vacías) o **Si** para que Gemini las llene (requiere la clave de la sección 4).

Si aparece «Se agotó el límite gratuito de la IA»

> **Opciones 3, 5 y 7**
> No es un error del programa: la clave gratuita de Gemini llegó a su límite diario. Lo extraído hasta ese momento queda guardado, pero el programa no genera el Excel porque la extracción está incompleta.
>
> Espera un día (el propio programa indica que el límite se reinicia normalmente a medianoche, hora del Pacífico de EE. UU.) y vuelve a ejecutar la misma opción: solo se procesará lo que quedó pendiente. También puedes usar una clave con facturación activa.

Mientras el programa trabaja

- Es normal que pasen varios minutos sin cambios visibles. El programa espera un segundo entre cada petición al sitio del Congreso para no saturarlo, y las opciones con IA esperan la respuesta del modelo.
- No cierres la ventana ni suspendas la computadora. Para cancelar, presiona Control+C. Las opciones 3, 5 y 7 (con IA) guardan su avance y continúan donde se quedaron.
- Ejecuta una sola opción a la vez y no abras el programa dos veces: dos ejecuciones simultáneas pueden escribir sobre los mismos archivos.

6. Dónde están los resultados

- Los archivos de Excel quedan en la carpeta `outputs`, con los nombres de la tabla de la sección 1.

- Los datos intermedios y los PDF descargados quedan en la carpeta `data`. No necesitas abrirlos, pero no los borres: las demás bases y las ejecuciones futuras los reutilizan, y así se evita volver a gastar IA.
- Cada ejecución sobrescribe el Excel anterior con el mismo nombre. Copia el archivo a otro lugar si quieres conservar versiones.
- Cierra el Excel antes de volver a ejecutar la misma opción. Si el archivo está abierto, Windows impide guardarlo y el programa falla.
- En las opciones 2 y 4 la revisión modifica el mismo Excel que se acaba de generar: agrega colores y comentarios en las celdas con diferencias (sección 10).

7. Ejecutar de nuevo otro día

No hay que repetir ninguna preparación: haz doble clic en `DataExtractionGP.exe` y elige la opción. Si recibes una actualización del programa, conserva tus carpetas `data` y `outputs` y el archivo `.env`: contienen tus resultados, el avance ya procesado y tu clave.

8. Orden recomendado y tiempos

Cada opción puede ejecutarse sola, pero algunas usan datos que generan otras. Si es la primera vez y quieres todas las bases, sigue este orden:

Orden	Opción	Motivo
Primero	1 Perfiles	La opción 7 necesita estos datos para asignar el partido a quien presenta cada iniciativa.
Segundo	5 Comisiones y comités	Requiere la clave de IA. La opción 7 necesita estos datos para turnar cada asunto a sus comisiones.
Tercero	6 Sesiones	Descarga las gacetas mensuales. La opción 4 las necesita para construir su Excel y la 7 las reutiliza sin descargarlas de nuevo.
Cuarto	4 Asistencias	Su Excel se construye con las gacetas de la opción 6; la revisión lo compara contra la página del Congreso.
Quinto	3 Unidad y participación	Requiere la clave de IA. La revisión de la opción 2 compara contra estos datos.
Sexto	2 Votaciones	Su revisión necesita los datos de la opción 3.
Último	7 Iniciativas y puntos de acuerdo	Requiere los datos de las opciones 1 y 5. Si falta alguno, no genera nada e indica cuál.

Tiempos. No existe una cifra fija; la primera ejecución completa es larga. Pesan sobre todo las opciones 3 y 5 (esperan a la IA) y las opciones 6 y 7 (procesan gacetas mensuales de cientos o miles de páginas). Las opciones 3 y 5 recuerdan lo que ya procesaron, así que en las siguientes ejecuciones solo trabajan con documentos nuevos o pendientes. Las opciones 1, 2, 4, 6 y 7 vuelven a recorrer todo en cada ejecución, aunque los PDF ya descargados no se descargan otra vez.

Uso de IA. Las opciones 3 y 5, y la 7 si eliges IA, consumen cuota de tu clave. El programa evita gastarla de más: no envía a la IA las actas sin conteo de votos, no repite documentos ya procesados y se detiene al agotarse el límite diario. Ten presente que el texto de esos documentos públicos del Congreso se envía a Google para su análisis, y que la salida de una IA puede contener errores: conviene revisar una muestra de los resultados.

9. Las siete bases de datos

Opción 1: Perfiles

Una fila por diputado con su formación académica, último grado de estudios, carrera, universidad (pública o privada), experiencia legislativa (Sí, No o «Sin información»), profesión, género, correo, teléfono de oficina, Facebook, Twitter, casa de gestión y si existe plan de trabajo. También descarga la foto de cada diputado en `data/photos`. El Excel tiene una hoja llamada «Hoja 1», ordenada por apellido paterno; las celdas sin dato muestran N/A. No usa IA.

Opción 2: Votaciones

Una fila por diputado (ordenados por apellido paterno) y una columna por votación, ordenadas por fecha. Debajo hay filas de totales. Los totales se calculan contando el voto de cada diputado; si difieren de los que muestra la página, el programa avisa en pantalla y usa su propio conteo. Cada votación se clasifica como iniciativa o punto de acuerdo. Al final se hace una revisión automática contra los datos de la opción 3, por eso conviene ejecutar antes la opción 3. No usa IA.

Opción 3: Unidad y participación

Es la base más compleja. Descarga las actas de sesión en PDF y usa IA para identificar cada votación con sus conteos. Las columnas del Excel son: Año Legislatura, Periodo, Folio periodo, Folio legislatura, Fecha, Tipo, Título, Tema 1, Tema, A favor, Contra, Abstenciones, Ausentes, Total, Porcentaje de Participación y Unidad. Las últimas tres se calculan solas: Total suma los cuatro conteos; Porcentaje de Participación es la parte de votos emitidos sobre el total; Unidad indica qué tan concentrada estuvo la votación en la opción más votada.

El programa recuerda qué actas ya analizó y, en las siguientes ejecuciones, solo envía a la IA las pendientes. Si una acta falla, al final aparece el reporte «ACTAS NO PROCESADAS»: vuelve a ejecutar la opción y se reintentará.

Opción 4: Asistencias

El Excel se construye con las gacetas mensuales que descarga la opción 6, por lo que **debes ejecutar la opción 6 antes**. Tiene una fila por diputado y una columna por sesión, en dos bloques: sesiones normales (previas, solemnes, ordinarias y extraordinarias) y sesiones de la Comisión Permanente. Cada bloque termina con una fila de totales por categoría, y una hoja adicional llamada «Claves» explica los códigos numéricos (sección 10). La página del Congreso se usa después, solo para la revisión automática. No usa IA.

Opción 5: Comisiones y comités

Genera un Excel con tres hojas: «Integrantes» (integrantes con género y partido, plan de trabajo, informes anuales y fecha de instalación), «Sesiones» (fechas de sesión por año legislativo, separadas en periodo ordinario y receso, con totales) y «Copia de Contenido trabajo» (una fila por sesión con asunto, presentador, partido, estatus, horario y observaciones). La hoja de contenido usa IA, por lo que esta opción **siempre necesita la clave**.

Cada sesión de la hoja de contenido lleva un «Estado de extracción»: Completo, Pendiente (hubo una falla y se reintentará al volver a ejecutar) o N/A (la sesión no tiene documento). La lista de pendientes queda en `data/registros_pendientes.json`.

Opción 6: Sesiones

Descarga la gaceta legislativa de cada mes y extrae los datos de cada sesión y su cronometría, sin IA. Una gaceta mensual puede tener más de mil páginas, por lo que esta opción es lenta. Los PDF que descarga los reutilizan las opciones 4 y 7. El Excel «Sesiones.xlsx» tiene una hoja llamada «Hoja 1» y varias columnas calculadas con fórmulas.

Opción 7: Iniciativas y puntos de acuerdo

Lee las gacetas mensuales y arma una fila por cada iniciativa o punto de acuerdo, con número, descripción, fecha de presentación, presentador, partido, turno a comisiones, estatus, fecha de aprobación y resultado de la votación. Una iniciativa o punto de acuerdo pasa a «Aprobada» cuando un dictamen la aprueba, aunque sea en otra sesión o en otra gaceta.

Necesita los datos de las opciones 1 y 5. Si falta alguno, el programa muestra «NO SE PUEDE EJECUTAR: faltan archivos de otras bases de datos», indica cuál ejecutar y no genera nada. El Excel «Iniciativas y PA.xlsx» separa los registros en las hojas «Iniciativas» y «Puntos de acuerdo» (más una hoja «Sin tipo», solo si hace falta) y una hoja «Hoja 3» con el catálogo de temas. La columna Tema se deja vacía para clasificarla a mano con ese catálogo. Las filas aprobadas se rellenan en verde.

10. Cómo leer los Excel

Votos en el Excel de Votaciones

Código	Significado	Color de la celda
1	A favor	Verde
2	En contra	Rojo
3	Abstención	Naranja
4	Voto secreto	Gris
0	Ausencia o sin voto	Blanco

Códigos del Excel de Asistencias

Código	Significado
1	Asistencia
2	Retardo justificado
3	Retardo injustificado
4	Inasistencia justificada
5	Inasistencia injustificada
6	Con licencia
7	Sin información
8	Fallecimiento

Colores de la revisión automática (opciones 2 y 4)

La revisión compara el Excel con otra fuente: en Votaciones, con los datos de la opción 3; en Asistencias, con la página del Congreso. Sirve para detectar errores en cualquiera de las dos fuentes. Marca las celdas así:

Color	Significado
Naranja	Ambas fuentes tienen dato, pero es distinto.
Amarillo	El Excel tiene dato y la otra fuente no lo lista.
Azul	La otra fuente tiene dato y el Excel está vacío o con un guion.

Cada celda marcada lleva un comentario con el valor de la otra fuente. En Asistencias, la revisión también agrega una hoja «Discrepancias» y solo compara las sesiones que existen en ambos lados. Una marca no siempre significa que el Excel esté mal: indica que las dos fuentes no coinciden y conviene revisar esa celda.

Legislatura, año legislativo y periodos

El año legislativo comienza el 15 de septiembre y cada legislatura dura tres años. Las columnas «Año Legislatura» y «Periodo» de los Excel siguen estas fechas. Los folios son números consecutivos por legislatura y por periodo, calculados en orden cronológico con los documentos procesados.

Periodo	Periodo ordinario	Receso posterior
Primero	15 de septiembre al 15 de diciembre	Hasta el 14 de enero
Segundo	15 de enero al 15 de marzo	Hasta el 14 de mayo
Tercero	15 de mayo al 15 de julio	Hasta el 14 de septiembre

11. Qué hacer cuando algo falla

Síntoma	Causa probable	Qué hacer
Windows muestra «Windows protegió su PC» al abrir el programa	Windows muestra este aviso con programas que no reconoce.	Elige «Más información» y luego «Ejecutar de todas formas». Si tu antivirus lo bloquea, pide al responsable técnico que lo agregue a las excepciones.
«No se encontró el archivo scrapper» o «… writer» y una ruta	Falta la carpeta `scrappers` o `writers` junto al ejecutable, o se movió o renombró.	Restaura la carpeta completa tal como se entregó (sección 3).
Las opciones 3 o 5 se detienen al iniciar. En la 7, aviso «IA desactivada»	Falta el archivo `.env`, está en otra carpeta (debe estar junto al `.exe`), tiene otro nombre (por ejemplo `.env.txt`) o no contiene `GEMINI_API_KEY`.	Revisa la sección 4. En la opción 7 puedes volver a ejecutar respondiendo No.
«La API key es inválida o no tiene permisos»	Clave incorrecta, vencida o revocada.	Crea una clave nueva en AI Studio y reemplázala en `.env`.
Panel «Ejecución detenida: Se agotó el límite gratuito de la IA» (opciones 3, 5 y 7)	Se alcanzó el límite diario de la clave gratuita.	Espera un día y ejecuta de nuevo la misma opción; solo se procesará lo pendiente. No se genera el Excel hasta completar la extracción.
«Se agotó la cuota» o error 429 sin ese panel	Se alcanzó el límite por minuto de la clave.	Espera un minuto y ejecuta de nuevo la misma opción. Solo se enviarán a la IA los documentos pendientes.
«Alta demanda» o error 5xx	El servicio de Gemini está saturado.	Intenta de nuevo más tarde. Lo ya procesado se conserva.
Reporte «ACTAS NO PROCESADAS» (opción 3) o registros «Pendiente» (opción 5)	La IA falló en algunos documentos.	Ejecuta de nuevo la opción. Los pendientes de la opción 5 se listan en `data/registros_pendientes.json`.
«La estructura de la página cambió» u otro error al leer el sitio	El Congreso modificó el diseño de su página y el programa ya no encuentra los datos.	Requiere que el responsable técnico actualice el programa. Anota la opción y el mensaje exacto.
Error de acceso (403, 404, tiempo agotado) al abrir páginas del Congreso	Sin internet, sitio caído o bloqueo temporal.	Verifica tu conexión y reintenta más tarde.
«NO SE PUEDE EJECUTAR: faltan archivos de otras bases de datos» (opción 7)	Todavía no existen los datos de la opción 1 o de la 5.	Ejecuta las opciones que indica el mensaje (1 y/o 5) y vuelve a la 7.
«No se encontró el archivo … asistencias_gacetas.json» o «No existe la carpeta de gacetas mensuales» (opción 4)	La opción 6 todavía no se ha ejecutado, así que no hay gacetas que leer.	Ejecuta la opción 6 y después la 4.
«Error durante la ejecución del Verificador» (opciones 2 y 4)	Falta el dato contra el que se compara: los de la opción 3 (para la 2) o los de la página del Congreso (para la 4).	Ejecuta la opción 3 antes que la 2, o vuelve a ejecutar la 4 completa. El Excel ya se había generado; solo falta la revisión.

Síntoma	Causa probable	Qué hacer
Al generar el Excel, el programa no encuentra el archivo de datos	La etapa de descarga no terminó, o se movió o borró la carpeta `data`.	Vuelve a ejecutar la opción completa desde el menú y no muevas ni borres `data`.
PermissionError al generar el Excel	El Excel está abierto.	Ciérralo y repite la opción.
Cualquier otro error	—	Anota la opción y la etapa en que ocurrió, copia el mensaje completo y envíalo al responsable técnico.

12. Glosario

Término	Significado
Ejecutable (.exe)	Programa que se abre con doble clic y no requiere instalar nada más.
Clave de API	Contraseña personal que permite usar el servicio de Gemini.
Gemini	Modelo de inteligencia artificial de Google usado para leer actas y documentos de comisiones, y opcionalmente para resumir iniciativas.
Límite o cuota diaria	Cantidad máxima de solicitudes que la clave gratuita de Gemini permite por día. Al agotarse hay que esperar a que se reinicie.
Acta	Documento que resume o transcribe una sesión.
Gaceta mensual	PDF mensual con el orden del día, documentos y asistencia de las sesiones del mes.
Orden del día	Lista numerada de los asuntos que se tratan en una sesión.
Dictamen	Documento con el que una comisión propone aprobar o rechazar una iniciativa o punto de acuerdo.
Versión estenográfica	Transcripción palabra por palabra de una sesión de comisión o comité.
Comisión y comité	Grupos de diputados que analizan temas específicos antes de que lleguen al pleno.
Iniciativa y punto de acuerdo	Dos tipos de asuntos que se presentan al Congreso: las iniciativas proponen leyes o reformas; los puntos de acuerdo expresan una postura o un exhorto.
Receso	Intervalo entre periodos ordinarios de sesiones.
Folio	Número consecutivo que identifica un registro dentro de una legislatura o un periodo.