Universidad Popular Autónoma del Estado de Puebla (UPAEP)

Área de Bien Común

Especificación de Requisitos de Software (SRS)

DataExtractionGP

Sistema de extracción, estructuración y verificación de datos del Congreso del Estado de Puebla (LXII Legislatura)

Control del documento	
Versión	1.0
Estado	SRS
Repositorio	github.com/Sam220903/DataExtractionGP
Autores del proyecto	Samuel Perez Guarneros, Alan David Jimenez Rodríguez

1. Introducción

1.1 Propósito

Este documento especifica los requisitos de DataExtractionGP, un sistema que recolecta información pública del Congreso del Estado de Puebla, la estructura y la entrega en hojas de cálculo de Excel. Sus destinatarios son el equipo de desarrollo, quien dé mantenimiento al sistema y el Área de Bien Común de la UPAEP, solicitante de los datos. Describe qué debe hacer el sistema, no cómo lo hace.

1.2 Alcance

El producto se denomina DataExtractionGP. Debe obtener, normalizar y entregar siete bases de datos de la LXII Legislatura:

1. Perfiles legislativos.
2. Votaciones.
3. Unidad y participación.
4. Registro de asistencias.
5. Comisiones legislativas y comités.
6. Sesiones y cronometría.
7. Iniciativas y puntos de acuerdo.

Para cada base el sistema cubre cuatro etapas: extracción, generación del Excel, verificación (solo bases 2 y 4) y orquestación desde un menú de consola.

Fuera de alcance: interfaz web, base de datos relacional, publicación en línea de los resultados, ejecución programada, pruebas automatizadas y verificadores para las bases 1, 3, 5, 6 y 7.

1.3 Definiciones, acrónimos y abreviaturas

Término	Definición
SRS	Software Requirements Specification: especificación de requisitos de software.
Acta	Documento PDF con el desarrollo de una sesión del Pleno; fuente de las votaciones.
Gaceta	Gaceta Legislativa mensual en PDF; fuente de asistencias y cronometría de sesiones.
Versión estenográfica (SV)	Transcripción íntegra de una sesión de comisión o comité.
Acta de comisión (PM)	Acta de una sesión de comisión o comité.
Pleno	Reunión de la totalidad de los diputados.
Comisión Permanente	Órgano que sesiona durante los recesos del Pleno.

Término	Definición
Folio legislatura / Folio periodo	Contadores secuenciales que ordenan los eventos dentro de la legislatura y de cada periodo.
PA	Punto de acuerdo: asunto legislativo distinto de la iniciativa.
Periodo	Ordinario o receso.
Scrapper / Writer / Verifier	Etapas de extracción, generación de Excel y verificación contra una segunda fuente.
IA generativa	Servicio externo de lenguaje (Gemini) que extrae datos de texto no estructurado.
MVP	Versión mínima que entrega las siete bases (sección 2.6).

1.4 Referencias

- Portal del Congreso del Estado de Puebla: www.congresopuebla.gob.mx (fuente de todos los datos).
- Plantillas Excel originales del Área de Bien Común.
- IEEE Std 830-1998, práctica recomendada para especificaciones de requisitos de software (estructura base).
- Repositorio del proyecto: github.com/Sam220903/DataExtractionGP.

1.5 Visión general del documento

La sección 2 describe el producto y su contexto. La sección 3 contiene los requisitos específicos: interfaces, funcionales por base, rendimiento, restricciones, atributos de calidad y datos. La sección 4 define los criterios de aceptación y la sección 5, la trazabilidad. Los apéndices recogen casos de uso, pendientes y la correspondencia con los identificadores de la versión 1.0.

Convenciones: la prioridad usa **Debe** (imprescindible para el MVP), **Debería** (importante, el MVP funciona sin ello) y **Podría** (deseable). El método de verificación usa **P** (prueba), **I** (inspección de código, archivos o documentos), **D** (demostración) y **A** (análisis de datos).

2. Descripción general

2.1 Perspectiva del producto

DataExtractionGP es una aplicación de consola autónoma. No depende de un servidor propio: consume el portal público del Congreso, procesa documentos PDF localmente y, solo en algunos casos, envía texto a un servicio externo de IA generativa. Los datos intermedios se guardan como JSON en la carpeta data/ y los entregables finales como Excel en la carpeta outputs/.

2.2 Funciones del producto

- Descargar y analizar páginas HTML y documentos PDF del portal.
- Extraer datos mediante reglas o mediante IA, según la complejidad del documento.
- Normalizar fechas, folios, tipos de evento, géneros, partidos y tipos de asistencia.
- Cruzar bases entre sí (por ejemplo, votaciones con presentaciones de iniciativas).
- Generar Excel con el formato de las plantillas originales.
- Verificar los Excel de las bases 2 y 4 contra una segunda fuente y marcar discrepancias.
- Reanudar procesos interrumpidos sin repetir trabajo ni volver a consumir IA.

2.3 Características de los usuarios

Rol	Descripción
Operador / analista	Ejecuta el sistema, elige una base y obtiene el Excel. No necesita conocimientos de programación ni modificar código.
Desarrollador	Mantiene la extracción, ajusta prompts y parámetros y administra la clave de la API de IA.
Área de Bien Común	Consumidor final de los Excel; define columnas y formato requeridos.

2.4 Restricciones generales

- La estructura HTML del portal puede cambiar sin aviso y afectar la extracción.
- La cuota y disponibilidad del servicio de IA limitan la velocidad del análisis.
- El portal aplica protección contra bots, por lo que las peticiones deben comportarse como las de un navegador y espaciarse.
- Los PDF descargados, el archivo .env y las pruebas no forman parte del repositorio.
- Entorno de ejecución: Python 3.11 o superior en Windows, macOS o Linux, con conexión a internet.

2.5 Suposiciones y dependencias

- El portal mantiene las rutas e identificadores de contenido usados (artículos 11527, 12718, 12715, 12716, 12868 y categorías 345, 369 y 409).
- La LXII Legislatura tiene 41 diputados; ese valor es el quórum por defecto cuando un acta no menciona la asistencia.
- La base 7 depende de los resultados de las bases 1, 3 y 5 y debe ejecutarse al final.

- La verificación de la base 2 depende de la base 3, y la de la base 4 depende de las gacetas.
- Se dispone de una clave válida de la API de IA para las bases 3 y 5.

2.6 Alcance del MVP

El MVP entrega las siete bases en Excel desde una copia limpia del repositorio sin modificar código. Se cumple cuando:

- **Cobertura.** Las siete bases generan su Excel desde el menú.
- **Repetibilidad.** Volver a ejecutar una base no duplica registros ni vuelve a consumir IA en documentos ya procesados.
- **Verificabilidad.** Las bases 2 y 4 pasan por su verificador y toda discrepancia queda marcada; el resto se revisa con los criterios de la sección 4.
- **Operabilidad.** Una persona sin conocimiento del código puede instalar, configurar y ejecutar el sistema con el manual de operación (documento aparte de este SRS).

3. Requisitos específicos

3.1 Interfaces externas

Interfaz de usuario

ID	Requisito	Prior.	Verif.
IF-01	El sistema deberá presentar una consola interactiva con una tabla que muestre número de opción, nombre de la base y estado, y un campo para elegir una opción de 0 a 7.	Debe	D
IF-02	El sistema deberá mostrar un indicador de actividad durante cada etapa y mensajes en verde ante éxito y en rojo ante error.	Debería	D
IF-03	El sistema deberá terminar de forma ordenada cuando el operador interrumpa con Ctrl+C.	Debe	P

Interfaces de software y comunicaciones

ID	Requisito	Prior.	Verif.
IF-04	El sistema deberá leer páginas HTML y descargar PDF del portal del Congreso (www.congresopuebla.gob.mx) por HTTPS, solo en modo lectura.	Debe	P
IF-05	El sistema deberá enviar a la API de IA generativa el prompt y el texto del documento, recibir JSON y autenticarse con la clave GEMINI_API_KEY.	Debe	P
IF-06	El sistema deberá generar y leer archivos .xlsx con estilos, fórmulas, comentarios y colores.	Debe	P

ID	Requisito	Prior.	Verif.
IF-07	El sistema deberá guardar los datos intermedios como JSON en UTF-8 sin escapar caracteres no ASCII.	Debe	I
IF-08	El sistema no deberá requerir hardware especial ni servidores propios.	Debe	I

3.2 Requisitos funcionales

3.2.1 Orquestación

ID	Requisito	Prior.	Verif.
RF-OR-01	El sistema deberá presentar un menú con las siete bases de datos y la opción de salir.	Debe	D
RF-OR-02	Al elegir una base, el sistema deberá ejecutar en orden la extracción, la generación del Excel y, si la base tiene verificador, la verificación.	Debe	P
RF-OR-03	El sistema deberá detener el flujo ante el primer error de una etapa e informar la etapa y la causa.	Debe	P
RF-OR-04	El sistema deberá informar el avance y un resumen final de cada ejecución, incluida la lista de documentos no procesados y su causa.	Debe	D
RF-OR-05	Antes de ejecutar la base 7, el sistema deberá comprobar que existen los resultados de las bases 1, 3 y 5 e indicar cuáles faltan.	Debería	P

3.2.2 Requisitos transversales

ID	Requisito	Prior.	Verif.
RF-TR-01	El sistema deberá asignar a cada registro de las bases 3, 4 y 6 el año de legislatura y el periodo (ordinario o receso) según la fecha del evento.	Debe	P
RF-TR-02	El sistema deberá asignar a cada registro de las bases 3, 4 y 6 un Folio legislatura y un Folio periodo secuenciales, reiniciando el contador al cambiar de legislatura o de periodo.	Debe	P
RF-TR-03	El sistema deberá clasificar cada evento legislativo como Iniciativa o Punto de Acuerdo.	Debe	A

ID	Requisito	Prior.	Verif.
RF-TR-04	El sistema deberá normalizar las fechas a un formato común y comparar textos sin distinguir acentos ni mayúsculas.	Debe	P
RF-TR-05	El sistema no deberá duplicar registros ni descargar de nuevo archivos existentes al volver a ejecutar una base.	Debe	P
RF-TR-06	El sistema deberá registrar de forma persistente cada documento analizado con IA, con su estado (analizado, pendiente o fallido), la versión del prompt y el modelo usado.	Debe	I
RF-TR-07	En ejecuciones posteriores, el sistema deberá procesar solo los documentos pendientes o fallidos, sin consumir IA en los ya procesados.	Debe	P
RF-TR-08	El sistema deberá generar para cada base un Excel con el formato de la plantilla original, incluidos estilos, colores y fórmulas donde corresponda.	Debe	I

3.2.3 Base 1 – Perfiles legislativos

Objetivo: datos básicos, académicos y de contacto de cada diputado. Fuente: Portal (listado) y la ficha individual de cada diputado. No usa IA ni tiene verificador.

ID	Requisito	Prior.	Verif.
RF-B1-01	El sistema deberá generar un registro por cada diputado de la legislatura (41 en la LXII).	Debe	A
RF-B1-02	Cada registro deberá incluir: nombre, partido, propietario o suplente, tipo de elección, distrito, género, folio de foto, plan de trabajo, experiencia legislativa, último grado de estudios, preparación, profesión, universidad, privada o pública, teléfono, correo, redes sociales y casa de gestión.	Debe	I
RF-B1-03	El sistema deberá determinar el último grado de estudios por jerarquía (de doctorado a bachillerato) y separar carrera y universidad.	Debe	P
RF-B1-04	El sistema deberá clasificar cada universidad como pública o privada.	Debe	P
RF-B1-05	El sistema deberá identificar la experiencia legislativa excluyendo suplencias y administraciones auxiliares.	Debe	P
RF-B1-06	El sistema deberá determinar el género de cada diputado.	Debe	A

ID	Requisito	Prior.	Verif.
RF-B1-07	El sistema deberá descargar la fotografía de cada diputado y asociarla a su registro.	Debe	I
RF-B1-08	El sistema deberá conservar el texto original de cada currículo y generar Perfiles.xlsx con el formato de Perfiles_Plantilla.xlsx.	Debe	I

3.2.4 Base 2 – Votaciones

Objetivo: voto individual de cada diputado en cada votación del Pleno. Fuente: Portal. No usa IA.

ID	Requisito	Prior.	Verif.
RF-B2-01	Para cada votación el sistema deberá obtener tema, fecha, sesión, número de votación, descripción, clasificación, periodo y tipo de votación.	Debe	I
RF-B2-02	El sistema deberá registrar el voto de cada diputado con los códigos 1 a favor, 2 en contra, 3 abstención, 0 no aplica y 4 secreta.	Debe	P
RF-B2-03	El sistema deberá contar a cada diputado en una sola categoría (ausente, a favor, en contra, abstención o no reconocido), de modo que la suma por votación sea igual al total de diputados.	Debe	A
RF-B2-04	El sistema deberá generar Votaciones.xlsx con una columna por votación, una fila por diputado y color según el sentido del voto.	Debe	I
RF-B2-05	El verificador deberá comparar a favor, en contra, abstenciones, ausencias y total de cada votación contra los resultados de la base 3, emparejando por fecha y similitud de texto con umbral configurable.	Debería	P

3.2.5 Base 3 – Unidad y participación

Objetivo: resultados agregados de cada votación del Pleno y porcentaje de participación. Fuente: actas del Pleno en PDF . Usa IA; no tiene verificador propio y su resultado es la referencia de la base 2.

ID	Requisito	Prior.	Verif.
RF-B3-01	El sistema deberá descargar las actas del Pleno en PDF sin repetir las ya descargadas.	Debe	P
RF-B3-02	El sistema deberá identificar en cada acta las votaciones y su resultado (a favor, en contra, abstenciones, ausentes y total), usando como evidencia el conteo de votos o la mención de unanimidad.	Debe	P
RF-B3-03	El sistema deberá excluir los votos de mero trámite (dispensas, lecturas y orden del día).	Debe	P
RF-B3-04	El sistema deberá clasificar cada votación como Iniciativa o Punto de Acuerdo y registrar título y tema.	Debe	A
RF-B3-05	El sistema deberá calcular el porcentaje de participación, entre 0 y 100, y usar 41 diputados como quórum cuando el acta no mencione la asistencia.	Debe	P
RF-B3-06	Si un acta no contiene conteo de votos ni unanimidad, el sistema deberá marcarla como analizada sin invocar la IA.	Debe	P
RF-B3-07	El sistema deberá ordenar los registros cronológicamente y asignarles año de legislatura, periodo y folios (RF-TR-01 y RF-TR-02).	Debe	A
RF-B3-08	El sistema deberá generar Unidad y Participación.xlsx con: año legislatura, periodo, folio periodo, folio legislatura, fecha, tipo, título, tema 1, tema, a favor, contra, abstenciones, ausentes, total, porcentaje de participación y unidad.	Debe	I

3.2.6 Base 4 – Registro de asistencias

Objetivo: asistencia de cada diputado a cada sesión. Fuente: detalle de sesión y gacetas mensuales como segunda fuente. No usa IA.

ID	Requisito	Prior.	Verif.
RF-B4-01	El sistema deberá extraer del portal la asistencia de cada diputado en cada sesión del Pleno y de la Comisión Permanente.	Debe	P
RF-B4-02	El sistema deberá clasificar cada asistencia con los códigos 1 asistencia, 2 retardo justificado, 3 retardo injustificado, 4 inasistencia justificada, 5 inasistencia injustificada, 6 con licencia, 7 sin información y 8 fallecimiento.	Debe	P
RF-B4-03	El sistema deberá calcular los totales por categoría de cada sesión y registrar clave de sesión, folios, año de legislatura, periodo, fecha y sesión.	Debe	P
RF-B4-04	El sistema deberá extraer asistencias desde las gacetas mensuales para usarlas como fuente de contraste.	Debería	P
RF-B4-05	El sistema deberá generar Asistencias.xlsx con filas por diputado, columnas por sesión, un bloque para sesiones normales y otro para la Comisión Permanente, totales y una hoja de claves.	Debe	I
RF-B4-06	El verificador deberá comparar Asistencias.xlsx contra las asistencias de las gacetas, emparejando sesiones por fecha y tipo, y marcar las discrepancias.	Debería	P
RF-B4-07	Las fechas deberán registrarse con año de cuatro dígitos.	Debe	I

3.2.7 Base 5 – Comisiones legislativas y comités

Objetivo: integración, actividad y contenido de trabajo de cada comisión y comité. Fuentes: categorías comisiones y comités del portal, con PDF de versiones estenográficas y actas de sesión. Usa IA solo para el contenido de las sesiones. No tiene verificador.

ID	Requisito	Prior.	Verif.
RF-B5-01	Para cada comisión y comité el sistema deberá registrar presidencia, secretarías y vocales con partido y género, número de integrantes, fecha de instalación y enlaces al plan de trabajo y a los informes anuales.	Debe	P
RF-B5-02	El sistema deberá contar y clasificar las sesiones de cada comisión y comité por año legislativo, periodo y receso.	Debe	P
RF-B5-03	Para cada sesión el sistema deberá descargar la versión estenográfica o el acta y extraer tipo de evento, asunto, fecha, hora de inicio y fin, presentador y partido.	Debe	P
RF-B5-04	El sistema deberá guardar el estado (éxito o fallo) de cada documento por su URL y no volver a procesar los exitosos.	Debe	P
RF-B5-05	El sistema deberá listar en registros_pendientes.json cada documento no procesado con su enlace, motivo y código de error.	Debe	I
RF-B5-06	El sistema deberá generar Comisiones.xlsx con tres hojas: Integrantes, Sesiones y Contenido (la plantilla la nombra “Copia de Contenido trabajo”).	Debe	I
RF-B5-07	En el Excel, los totales de sesiones deberán ser fórmulas y la columna Tiempo deberá ser fórmula cuando existan hora de inicio y de fin.	Debe	I
RF-B5-08	El sistema deberá dejar el contenido de las sesiones disponible como insumo de la base 7.	Debe	I

3.2.8 Base 6 – Sesiones y cronometría

Objetivo: duración, retraso de inicio y avance del orden del día de cada sesión del Pleno. Fuente: gacetas legislativas mensuales en PDF, algunas de más de 1,500 páginas. No usa IA ni tiene verificador.

ID	Requisito	Prior.	Verif.
RF-B6-01	El sistema deberá segmentar cada gaceta por sesión y registrar número de sesión, año y periodo de legislatura, tipo de sesión normalizado y fecha.	Debe	P
RF-B6-02	El sistema deberá extraer hora de cita, hora de inicio y hora de fin, incluso cuando estén escritas con palabras.	Debe	P
RF-B6-03	El sistema deberá calcular el retraso de inicio y la duración de cada sesión.	Debe	P
RF-B6-04	El sistema deberá registrar asuntos programados, abordados y no abordados, y calcular el porcentaje y el coeficiente de asuntos abordados.	Debe	P
RF-B6-05	Cuando la gaceta no indique la hora de cita, el sistema deberá usar una estimación y asentarlo en Observaciones.	Debe	P
RF-B6-06	El sistema deberá reportar como atípicos los retrasos mayores a un umbral configurable (180 minutos por defecto).	Debería	P
RF-B6-07	El sistema deberá generar Sesiones.xlsx con las columnas derivadas (K, L, M, P, S, T y U de la plantilla) como fórmulas de Excel.	Debe	I

3.2.9 Base 7 – Iniciativas y puntos de acuerdo

Objetivo: una fila por iniciativa o punto de acuerdo, con quién la presentó, su partido, la comisión de turno, el resultado de la votación y el tiempo entre presentación y aprobación. Se alimenta de las bases 1, 3 y 5. No tiene verificador; el archivo de revisión cumple esa función.

ID	Requisito	Prior.	Verif.
RF-B7-01	El sistema deberá generar una fila por cada votación de iniciativa o punto de acuerdo de la base 3	Debe	P
RF-B7-02	Para cada asunto el sistema deberá obtener presentador, partido, descripción, fecha de presentación y hasta seis comisiones de turno.	Debe	P
RF-B7-03	El sistema deberá vincular cada votación con su presentación por fecha, similitud de texto ponderada y compatibilidad de	Debe	P

ID	Requisito	Prior.	Verif.
	la ley citada, con umbrales configurables (por defecto 0.45 si el título nombra la comisión y 0.65 si no).		
RF-B7-04	El sistema deberá obtener el partido del presentador a partir de los perfiles de la base 1.	Debe	P
RF-B7-05	El sistema deberá registrar estatus, fecha de aprobación y diferencia en días entre presentación y aprobación, en valor absoluto por defecto y con signo si se configura.	Debe	P
RF-B7-06	El sistema deberá guardar los casos de vinculación dudosa o ambigua en un archivo de revisión para su análisis humano.	Debería	I
RF-B7-07	El sistema deberá guardar un resumen con los conteos del cruce.	Debería	I
RF-B7-08	El sistema deberá generar Iniciativas y PA.xlsx con las hojas Iniciativas, Puntos de acuerdo y temas, y las columnas: número, tipo, descripción, fecha de presentación, presentador, partido, tema, comisiones C1 a C6, estatus, fecha de aprobación, diferencia de días, año, contenido, comentario y votos (F, C, A).	Debe	I
RF-B7-09	El sistema deberá poder extraer las presentaciones directamente de las actas en PDF locales, descargando las faltantes, y permitir trabajar solo con archivos locales o ignorar la caché y releer los PDF.	Podría	P

3.3 Requisitos de rendimiento

ID	Requisito	Prior.	Verif.
RNF-REN-01	Las peticiones al portal deberán espaciarse al menos 1 segundo.	Debe	I
RNF-REN-02	El sistema deberá procesar gacetas de más de 1,500 páginas sin interrumpirse.	Debe	P
RNF-REN-03	Al rehacer una base (borrando sus JSON), el sistema deberá reutilizar los PDF ya descargados.	Debe	P

3.4 Restricciones de diseño

ID	Requisito	Prior.	Verif.
RNF-DIS-01	El sistema deberá ejecutarse en Python 3.11 o superior sobre Windows, macOS y Linux, calculando las rutas a partir de la ubicación de sus scripts.	Debe	P
RNF-DIS-03	La IA solo deberá usarse en las bases 3 y 5 (contenido de sesiones); las demás deberán extraer con reglas (el uso de IA en la base 7 es opcional).	Debe	I
RNF-DIS-04	Los procesos de cada base deberán ser independientes entre sí, salvo la dependencia de la base 7 con las bases 1, 3 y 5.	Debe	I
RNF-DIS-05	Las peticiones al portal deberán presentarse como las de un navegador para sortear su protección contra bots.	Debe	P

3.5 Atributos de calidad

ID	Categoría	Requisito	Prior.	Verif.
RNF-COS-01	Costo	El uso de IA deberá minimizarse mediante prefiltros por reglas, cachés y registros de control.	Debe	I
RNF-FIA-01	Confiabilidad	Ante errores transitorios de la API (5xx, límite por minuto, red) el sistema deberá reintentar con espera creciente, hasta 4 intentos por documento y con espera máxima de 10 segundos en versiones estenográficas y actas de comisión.	Debe	P
RNF-FIA-02	Confiabilidad	El sistema deberá detener el análisis con IA tras 3 fallos consecutivos, o de inmediato ante un error fatal (cuota diaria agotada o credenciales inválidas), conservando lo procesado y dejando el resto como pendiente.	Debe	P
RNF-FIA-03	Confiabilidad	Si el modelo no devuelve un JSON válido, el documento deberá marcarse como fallido.	Debe	P
RNF-FIA-04	Confiabilidad	El sistema deberá distinguir los errores: alta demanda, cuota agotada, cuota diaria agotada, credenciales inválidas,	Debe	I

ID	Categoría	Requisito	Prior.	Verif.
		error de red, respuesta inválida, sin descarga, sin texto, sin fecha y no intentado.		
RNF-FIA-05	Recuperabilidad	El progreso deberá escribirse a disco tras cada cambio para que una interrupción no pierda trabajo.	Debe	P
RNF-FIA-06	Confiabilidad	El sistema deberá avisar cuando no encuentre las secciones esperadas del portal.	Debe	P
RNF-SEG-01	Seguridad	La clave de la API deberá leerse de una variable de entorno (archivo .env excluido de Git) y nunca almacenarse en el código.	Debe	I
RNF-SEG-02	Seguridad	El sistema solo deberá recolectar información que el Congreso publique abiertamente.	Debe	I
RNF-USA-01	Usabilidad	El operador deberá recibir mensajes claros de avance, error y resumen, con la lista de documentos no procesados y su causa.	Debe	D
RNF-USA-02	Usabilidad	Una persona sin conocimiento del código deberá poder instalar, configurar y ejecutar el sistema con el manual de operación.	Debe	D
RNF-MAN-01	Mantenibilidad	La lógica común (descarga de PDF, fechas, folios, clasificación, registro y caché) deberá residir en módulos reutilizables.	Debe	I
RNF-MAN-02	Mantenibilidad	Deberán ser configurables sin cambiar la lógica: actas a reanalizar, reanálisis por prompt anterior, versión del prompt, límite de fallos de IA, umbrales de similitud, retraso atípico y signo de la diferencia de días.	Debería	I
RNF-TRZ-01	Trazabilidad	Cada análisis con IA deberá guardar la versión del prompt y el modelo; subir la	Debe	I

ID	Categoría	Requisito	Prior.	Verif.
		versión del prompt deberá invalidar los análisis previos.		
RNF-COM-01	Compatibilidad	Los Excel deberán abrirse sin errores en Microsoft Excel y conservar las fórmulas para recalcular al editar los datos.	Debe	P
RNF-COM-02	Compatibilidad	El menú deberá limpiar la pantalla correctamente en Windows, macOS y Linux.	Debería	P

3.6 Requisitos de datos

Los JSON se guardan en data/ con codificación UTF-8. Los PDF se guardan en data/pdfs/ según su tipo: minutes (actas del Pleno), gms (gacetas), svs (versiones estenográficas) y pms (actas de comisión). La mayoría de los JSON tiene la forma {“registros”: […]}; comisiones_*.json, sesiones.json e iniciativas_pa.json son arreglos directos.

Archivo	Origen	Consumidor	Contenido
perfiles.json, curriculos_raw.json	Base 1	Writer 1, base 7	Perfil de cada diputado y texto original del currículo.
votaciones.json	Base 2	Writer 2	Voto por diputado en cada votación.
unidad_participacion.json (y respaldo)	Base 3	Writer 3, verificador 2, base 7	Resultado agregado de cada votación con folios.
actas_registro.json	Base 3	Base 3	Actas descargadas, analizadas (con versión de prompt y modelo) o fallidas.
asistencias.json, asistencias_gacetas.json	Base 4	Writer 4, verificador 4	Asistencia por sesión; la segunda es la fuente de contraste.
comisiones_integrantes.json, comisiones_sesiones.json	Base 5	Writer 5	Integrantes y conteo de sesiones por comisión.
comisiones_contenido.json	Base 5	Writer 5, base 7	Sesiones con tipo, asunto, fecha, presentador y partido.
extraction_cache.json, registros_pendientes.json	Base 5	Base 5	Estado por URL y documentos no procesados con su causa.

Archivo	Origen	Consumidor	Contenido
sesiones.json	Base 6	Writer 6	Cronometría de cada sesión.
actas_presentaciones.json	Base 7 (actas PDF)	Base 7	Caché de presentaciones leídas de las actas.
iniciativas_pa.json, iniciativas_pa_revision.json, iniciativas_pa_resumen.json	Base 7	Writer 7	Filas finales, casos a revisar y conteos del cruce.

4. Criterios de aceptación

Base	El MVP se acepta si…
1. Perfiles	Genera 41 registros, cada uno con partido, género y fotografía, y Perfiles.xlsx abre sin errores.
2. Votaciones	Cada votación suma sus categorías al total de diputados y el verificador no deja discrepancias sin explicar contra la base 3.
3. Unidad y participación	Cada acta queda registrada como analizada, pendiente o fallida; no hay registros duplicados; el porcentaje de participación está entre 0 y 100.
4. Asistencias	Cada sesión tiene un código de asistencia por diputado y las diferencias contra las gacetas quedan marcadas.
5. Comisiones y comités	Hay un registro por comisión y comité en las tres hojas y los documentos no procesados aparecen en registros_pendientes.json con su causa.
6. Sesiones y cronometría	Cada sesión de las gacetas tiene fecha, inicio, fin y duración, y los valores estimados se explican en Observaciones.
7. Iniciativas y PA	Cada votación genera una fila con tipo, presentador y partido, y los casos dudosos quedan en el archivo de revisión.
Todas	Un segundo arranque no duplica filas, no repite descargas ni consumo de IA, y los Excel conservan fórmulas y formato al abrirse en Microsoft Excel.

Apéndice A. Casos de uso

ID	Caso de uso	Actor	Flujo principal	Flujos alternos y resultado
CU-01	Extraer una base	Operador	Elige la base en el menú; se ejecutan extracción, Excel y verificación si existe.	Si una etapa falla, el flujo se detiene e informa la causa. Resultado: JSON en data/ y Excel en outputs/.
CU-02	Reanudar tras una interrupción	Operador	Vuelve a ejecutar la misma base; solo se procesan documentos pendientes o fallidos.	Con cuota diaria agotada, el sistema se detiene y deja pendientes; se ejecuta de nuevo al día siguiente. Resultado: sin duplicados ni gasto repetido de IA.
CU-03	Verificar un Excel	Operador	En las bases 2 y 4 la verificación corre tras el Excel.	Resultado: discrepancias marcadas con color y comentario.
CU-04	Reanalizar actas	Desarrollador	Define las actas a reanalizar o el reanálisis por prompt anterior y ejecuta la base 3.	Resultado: actas reanalizadas con la versión vigente del prompt.
CU-05	Generar Iniciativas y PA	Operador	Con las bases 1, 3 y 5 generadas, ejecuta la base 7.	Si el portal cambió su estructura, el sistema avisa y se ajusta el scrapper. Resultado: Excel y archivo de casos a revisar.
CU-06	Entregar al Área de Bien Común	Operador	Revisa los Excel y los archivos de revisión y envía los entregables.	Resultado: bases con el formato de las plantillas.